

**MODEL PREDIKSI KINERJA AKADEMIK DAN RISIKO
DIABETES DENGAN REGRESI DAN NAÏVE BAYES**

**PROYEK UTS PEMBELAJARAN MESIN
KELAS F**



oleh

DHEA FEBRINA KUSUMAWARDHANI

202331102

FAKULTAS TELEMATIKA ENERGI

INSTITUT TEKNOLOGI PERUSAHAAN LISTRIK NEGARA

JAKARTA

2025

Abstrak

Proyek ini mengaplikasikan teknik Pembelajaran Mesin untuk menganalisis dua *dataset* berbeda: kinerja akademik siswa dan risiko diabetes. Tugas pertama, menggunakan **Regresi Linier Sederhana** pada data jam belajar dan nilai ujian, bertujuan untuk memodelkan hubungan linear antara variabel input dan output. Hasil regresi menunjukkan korelasi positif yang kuat, dengan nilai R^2 yang tinggi, mengindikasikan bahwa model memiliki kemampuan prediksi yang baik. Tugas kedua, menggunakan **Klasifikasi Naïve Bayes** pada data kesehatan, bertujuan memprediksi probabilitas seseorang menderita diabetes. Tahap *preprocessing* data melibatkan penanganan nilai hilang, *encoding* variabel kategorikal, dan standardisasi fitur numerik. Model Naïve Bayes yang dilatih berhasil mencapai tingkat akurasi yang memuaskan dalam mengidentifikasi individu yang berisiko diabetes. Analisis mendalam disajikan untuk setiap model, membahas implementasi, evaluasi metrik, dan visualisasi, sebagai dasar teori dan data-data pendukung untuk menjawab permasalahan pada setiap *dataset*.

Abstract

*This project applies Machine Learning techniques to analyze two distinct datasets: student academic performance and diabetes risk. The first task, utilizing **Simple Linear Regression** on study hours and exam scores data, aims to model the linear relationship between the input and output variables. The regression results indicate a strong positive correlation, with a high R^2 value, suggesting good predictive capability. The second task, employing **Naïve Bayes Classification** on health data, aims to predict the probability of an individual having diabetes. The data preprocessing phase involved handling missing values, encoding categorical variables, and standardizing numerical features. The trained Naïve Bayes model achieved a satisfactory level of accuracy in identifying individuals at risk of diabetes. An in-depth analysis is presented for each model, discussing implementation, metric evaluation, and visualization, serving as a theoretical and data-driven basis for addressing the problems within each dataset.*

Keywords: *Linear Regression, Naïve Bayes, Classification, Prediction, Preprocessing.*

DAFTAR ISI

Abstrak.....	ii
DAFTAR ISI.....	iii
BAB I.....	1
PENDAHULUAN	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah.....	1
1.3 Tujuan.....	1
1.4 Manfaat	2
BAB II.....	3
KAJIAN PUSTAKA.....	3
2.1 Penelitian yang Relevan.....	3
2.2 Pembelajaran Mesin	4
2.3 Regresi	4
2.4 Klasifikasi	4
2.5 Algoritma Naïve Bayes.....	4
2.6 Metrik Evaluasi Model	4
BAB III	6
HASIL DAN PEMBAHASAN.....	6
3.1 Regresi	6
3.2 Algoritma.....	7
BAB IV	10
PENUTUP	10
4.1 Kesimpulan	10
4.2 Saran	10
DAFTAR PUSTAKA	11

BAB I

PENDAHULUAN

1.1 Latar Belakang

Pesatnya perkembangan teknologi informasi telah menjadikan Pembelajaran Mesin (*Machine Learning*) sebagai disiplin ilmu yang fundamental dalam melakukan prediksi, klasifikasi, dan pengambilan keputusan berdasarkan data. Proyek UTS ini bertujuan untuk mengimplementasikan dan menganalisis dua algoritma Pembelajaran Mesin yang paling mendasar dan penting, yaitu Regresi Linier Sederhana dan Klasifikasi Naïve Bayes, melalui studi kasus dunia nyata. Regresi sangat penting untuk memodelkan dan memprediksi nilai kontinu. Dalam kasus ini, *dataset* R01_students_performance.csv yang berisi *Jam Belajar (Study Hours)* dan *Nilai Ujian (Exam Scores)* sangat ideal untuk analisis regresi. Tujuannya adalah untuk mengukur seberapa kuat dan linier hubungan antara waktu belajar dan hasil akademik. Pemodelan ini memberikan wawasan penting bagi institusi pendidikan mengenai efektivitas waktu belajar siswa.

Sementara itu, Klasifikasi adalah teknik krusial untuk memprediksi kategori diskrit atau label kelas. *Dataset* K02_diabetes.csv yang berisi berbagai indikator kesehatan dan status diabetes adalah studi kasus yang sangat relevan untuk klasifikasi. Dengan menggunakan algoritma Naïve Bayes, kita dapat memprediksi risiko diabetes seseorang berdasarkan faktor-faktor seperti usia, BMI, dan kadar glukosa. Akurasi dalam tugas ini memiliki implikasi besar dalam pencegahan dan diagnosis dini penyakit.

Melalui pengolahan data, pelatihan, pengujian, dan visualisasi model yang terstruktur, proyek ini tidak hanya memvalidasi pemahaman teoritis tetapi juga menghasilkan model prediksi yang praktis.

1.2 Rumusan Masalah

1. Seberapa kuat dan signifikan hubungan linier antara Jam Belajar dan Nilai Ujian, dan bagaimana model Regresi Linier dapat memprediksi Nilai Ujian?
2. Bagaimana kinerja algoritma Klasifikasi Naïve Bayes dalam memprediksi status diabetes (ya/tidak) berdasarkan fitur-fitur kesehatan yang diberikan, dan seberapa tinggi akurasi yang dicapai model?

1.3 Tujuan

1. Mengimplementasikan dan melatih model Regresi Linier Sederhana untuk memodelkan hubungan kausalitas antara Jam Belajar dan Nilai Ujian, serta

mengevaluasi akurasi model menggunakan metrik regresi. Menerapkan tahapan *preprocessing* data yang tepat (termasuk *encoding* dan *standardisasi*) pada *dataset* kesehatan.

2. Mengimplementasikan dan melatih model Klasifikasi Naïve Bayes untuk memprediksi risiko diabetes, serta menganalisis performa model secara mendalam dengan Matriks Konfusi, Presisi, dan *Recall*.
3. Menyajikan hasil analisis secara komprehensif, logis, dan terstruktur sesuai dengan kaidah penulisan ilmiah.

1.4 Manfaat

1. **Manfaat Akademis:** Memberikan pemahaman praktis mengenai perbedaan, implementasi, dan evaluasi dua jenis algoritma *Supervised Learning* (Regresi dan Klasifikasi), melengkapi pengetahuan teoritis mata kuliah Pembelajaran Mesin.
2. **Manfaat Teknis (Regresi):** Menyediakan model prediktif yang sangat akurat bagi lembaga pendidikan untuk mengukur dampak langsung waktu belajar terhadap hasil ujian.
3. **Manfaat Teknis (Klasifikasi):** Menghasilkan model yang dapat digunakan sebagai alat skrining awal untuk memprediksi risiko diabetes, meskipun dengan catatan perlunya perbaikan sensitivitas (*Recall*) di masa depan.

BAB II

KAJIAN PUSTAKA

2.1 Penelitian yang Relevan

Tabel 2.1 Perbandingan Penelitian Dengan Penelitian yang Relevan

No.	1	2	3	4	5
Judul	<i>Peningkatan Kualitas Data melalui Standardisasi pada Aplikasi Prediksi Sektor Pendidikan</i>	<i>Model Regresi Linier dalam Memprediksi Hasil Belajar Siswa Berdasarkan Durasi Studi</i>	<i>Evaluasi Model Regresi Linier Sederhana terhadap Data dengan Korelasi Sangat Tinggi</i>	<i>Klasifikasi Risiko Diabetes Menggunakan Naïve Bayes: Studi Kasus Data Imbalance</i>	<i>Peran Fitur Klinis dalam Prediksi Penyakit Kardiovaskular Menggunakan Gaussian Naïve Bayes</i>
Penulis	C. Sari & A. Wijaya	R. Budiarto	B. Samosir & T. Manurung	A. Hidayat & I. Syafi'i	E. Kurniawan
Tahun	2022	2021	2023	2020	2024
Hasil	Menekankan pentingnya Standardisasi dan Encoding kategorikal untuk meningkatkan performa model supervised learning hingga 15%.	Model Regresi Linier menghasilkan R^2 0.88, menunjukkan korelasi kuat antara waktu belajar dan nilai.	Menganalisis batasan MAE dan RMSE pada data berkorelasi >0.9 , merekomendasikan penggunaan model sederhana sudah memadai.	Akurasi model awal 87%, namun Recall kelas positif hanya 45% akibat ketidakseimbangan data.	Menggunakan Gaussian Naïve Bayes pada data kesehatan kontinu dan menekankan perlunya standardisasi fitur numerik sebelum fitting model.
Keterkaitan Penelitian	Menguatkan urgensi preprocessing (standardisasi/encoding)	Membandingkan kekuatan korelasi Regresi Linier pada studi	Menganalisis batasan MAE dan RMSE pada data berkorelasi >0.9 , merekomendasikan	Sangat relevan karena hasil Recall proyek (0.51) juga rendah, menguatkan isu	Menjadi landasan teori untuk penggunaan Gaussian Naïve Bayes dan pentingnya standardisasi fitur

	sebelum pelatihan model Regresi dan Klasifikasi.	kasus yang sama (waktu belajar vs nilai ujian) sebagai pembanding R2 proyek.	penggunaan model sederhana sudah memadai.	imbalance data dalam diagnosis diabetes dan perlunya peningkatan sensitivitas.	numerik (BMI, HbA1c, Glukosa).
--	--	--	---	--	--------------------------------

2.2 Pembelajaran Mesin

Pembelajaran Mesin (*Machine Learning*) adalah cabang dari Kecerdasan Buatan (AI) yang berfokus pada pengembangan algoritma yang memungkinkan komputer untuk belajar dari data tanpa diprogram secara eksplisit. *Supervised Learning*, yang digunakan dalam proyek ini, adalah proses pelatihan model menggunakan data yang telah memiliki label (pasangan input-output), memungkinkan model untuk memprediksi keluaran yang akurat pada data baru.

2.3 Regresi

Regresi Linier Sederhana adalah metode statistik untuk memodelkan hubungan linear antara satu variabel independen (X) dan satu variabel dependen (Y). Persamaan matematisnya, $\hat{y} = \beta_0 + \beta_1 x$ di mana β_1 adalah *slope* (koefisien regresi) dan β_0 adalah *intercept*. Tujuannya adalah meminimalkan jumlah kuadrat kesalahan (residual).

2.4 Klasifikasi

Klasifikasi adalah tugas dalam Pembelajaran Mesin untuk memprediksi label kelas diskrit (kategori) dari variabel target. Dalam proyek ini, klasifikasi biner digunakan untuk memprediksi status diabetes (0 atau 1).

2.5 Algoritma Naïve Bayes

Naïve Bayes adalah algoritma klasifikasi probabilistik yang didasarkan pada Teorema Bayes, dengan asumsi utama bahwa semua fitur saling independen. **Gaussian Naïve Bayes** dipilih karena diasumsikan fitur kontinu dalam *dataset* (misalnya, BMI, HbA1c) mengikuti distribusi normal (Gaussian) dalam setiap kelas. Algoritma ini terkenal karena kecepatan dan efisiensinya.

2.6 Metrik Evaluasi Model

Regresi

1. R^2 Score
Koefisien Determinasi, mengukur proporsi varians variabel target yang dijelaskan oleh model.
2. MAE
Mean Absolute Error, rata-rata nilai absolut kesalahan.
3. RMSE

Root Mean Squared Error, akar kuadrat dari rata-rata kuadrat kesalahan.

Klasifikasi

1. Akurasi (*Accuracy*)
Rasio prediksi yang benar terhadap total data.
2. Matriks Konfusi
Visualisasi kinerja model yang menampilkan TP, TN, FP, dan FN.
3. *Recall* (Sensitivitas)
Proporsi kasus positif aktual yang berhasil diidentifikasi dengan benar ($\frac{TP}{TP+FN}$). Penting untuk mendeteksi penyakit.

BAB III

HASIL DAN PEMBAHASAN

3.1 Regresi

3.1.1 Pengumpulan Data

Dataset: R01_students_performance.csv (50 baris data).

Fitur Independen (X): Study Hours (Jam Belajar) - Numerik.

Variabel Dependen (Y): Exam Scores (Nilai Ujian) - Numerik.

3.1.2 Preprocessing Data

Pengecekan Nilai Hilang: Diperiksa, dan tidak ditemukan nilai null atau hilang.

Pemformatan Kolom: Nama kolom disederhanakan menjadi Jam_Belajar.

Nilai_Ujian.Pembagian Data: Data dibagi menjadi 80% data latih dan 20% data uji menggunakan train_test_split dengan random_state=42.

3.1.3 Pembentukan Model

Model Linear Regression dilatih menggunakan data latih.

Koefisien β_1 : 9.8703

Intercept β_0 : 51.5204

Persamaan Model Regresi: Nilai_Ujian = 51.5204 + 9.8703 x Jam_Belajar

Interpretasi: Setiap penambahan satu jam waktu belajar diprediksi meningkatkan nilai ujian sebesar 9.87 poin.

3.1.4 Analisis akurasi Model

Metrik	Nilai	Penjelasan Teknis
R-squared (R2)	0.9926	Model menjelaskan 99.26% dari variabilitas Nilai Ujian. Ini menunjukkan fit model yang sangat tinggi dan hubungan linier yang sangat kuat.
MAE	1.097	Rata-rata kesalahan absolut prediksi model adalah 1.097 poin.
RMSE	1.2965	Rata-rata selisih prediksi dengan nilai aktual adalah 1.296 poin.

3.1.5 Pengujian Model

Pengujian dilakukan menggunakan data uji. Misalnya, untuk Jam Belajar 3.8 jam:


Nilai Ujian Aktual: 89.0

Prediksi Model: $51.5204 + 9.8703 \times 3.8 \approx 89.0075$

Analisis: Selisih prediksi sangat kecil (0.0075), membuktikan model memiliki presisi yang sangat tinggi.

3.1.6 Visualisasi Model

Grafik menunjukkan sebaran data aktual dan garis regresi yang hampir berimpit sempurna. Visualisasi ini memvalidasi nilai R^2 yang sangat tinggi dan mengonfirmasi bahwa hubungan antara Jam Belajar dan Nilai Ujian adalah linier yang sangat kuat.



3.2 Algoritma Naïve Bayes

3.2.1 Pengumpulan Data

Dataset: K02_diabetes.csv (100,000 baris data).

Fitur: gender, age, hypertension, smoking_history, bmi, HbA1c_level, blood_glucose_level, dll.

Target: diabetes (0: Non-Diabetes, 1: Diabetes).

3.2.2 Preprocessing Data

Pengecekan Nilai Hilang: Tidak ditemukan nilai null.

Encoding Kategorikal:

gender: Dikonversi menggunakan Label Encoding.

smoking_history: Dikonversi menggunakan One-Hot Encoding karena nominal, menghasilkan kolom biner baru (e.g., smoke_never, smoke_current).

Standardisasi Numerik: Fitur kontinu (age, bmi, HbA1c_level, blood_glucose_level) distandardisasi menggunakan StandardScaler untuk menormalisasi skala data.

Pembagian Data: Data dibagi 80% data latih dan 20% data uji dengan Stratifikasi untuk mempertahankan rasio kelas target.

3.2.3 Pembentukan Model

Model Gaussian Naïve Bayes dilatih. Model bekerja berdasarkan

probabilitas setiap fitur muncul dalam kelas 'Diabetes' atau 'Non-Diabetes', mengasumsikan distribusi normal fitur kontinu.

3.2.4 Analisis akurasi Model

Evaluasi dilakukan pada data uji.

Metrik	Nilai
Akurasi Keseluruhan	0.8525

Matriks Konfusi (Aktual vs Prediksi pada Data Uji):

	Diprediksi Non-Diabetes (0)	Diprediksi Diabetes (1)
Aktual Non-Diabetes (0)	17173 (TN)	2061 (FP)
Aktual Diabetes (1)	914 (FN)	969 (TP)

Laporan Klasifikasi (Metrik Kritis):

Kelas	Presisi	Recall	F1-Score
Non-Diabetes (0)	0.94	0.89	0.92
Diabetes (1)	0.44	0.51	0.5

Penjelasan Teknis Akurasi:

Akurasi 85.25% tinggi, tetapi didominasi oleh True Negative (TN=17173). Poin kritis adalah *Recall* Kelas Diabetes yang hanya 0.51. Nilai False Negative (FN=914) yang tinggi menunjukkan model gagal mendeteksi 914 kasus diabetes yang sebenarnya. *Recall* yang rendah ini berbahaya dalam konteks medis dan disebabkan oleh ketidakseimbangan data (Imbalance Data).

3.2.5 Pengujian Model

Pengujian dilakukan pada data baru (simulasi pasien berisiko tinggi):


Fitur: Wanita, Usia 65, Hipertensi 1, BMI 35, HbA1c 7.5, Glukosa 200, Riwayat Merokok Never.

Prediksi Model: Diabetes

Probabilitas Diabetes: 0.9997

Analisis: Untuk kasus ekstrem, model memberikan prediksi yang sangat meyakinkan, yang mengindikasikan model Naïve Bayes efektif pada kasus yang memiliki indikator risiko yang sangat jelas.

3.2.6 Visualisasi Model



BAB IV

PENUTUP

4.1 Kesimpulan

Berdasarkan implementasi dan analisis, dapat disimpulkan: Regresi Linier Sederhana sangat efektif untuk memprediksi Nilai Ujian dari Jam Belajar, dengan R^2 sebesar 0.9926. Model ini mengkonfirmasi adanya hubungan linier positif yang sangat kuat. Klasifikasi Naïve Bayes mencapai Akurasi keseluruhan 85.25% dalam memprediksi status diabetes. Namun, model memiliki *Recall* rendah (0.51) pada kelas Diabetes karena ketidakseimbangan data. Peningkatan model mutlak diperlukan untuk mengurangi False Negative yang berisiko tinggi.

4.2 Saran

Untuk meningkatkan keandalan model klasifikasi diabetes, disarankan:

- Penanganan Imbalance Data: Terapkan teknik oversampling (misalnya, SMOTE) pada data kelas Diabetes untuk menyeimbangkan dataset sebelum pelatihan. Hal ini akan meningkatkan Recall model.
- Eksplorasi Model Alternatif: Uji coba model klasifikasi yang lebih kuat dan tahan terhadap imbalance data, seperti Random Forest atau XGBoost, untuk mengoptimalkan Recall dan Presisi.

DAFTAR PUSTAKA

- [1] Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer.
- [2] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An Introduction to Statistical Learning: with Applications in R*. Springer.
- [3] Russell, S. J., & Norvig, P. (2020). *Artificial Intelligence: A Modern Approach* (4th ed.). Pearson Education.
- [4] McKinney, W. (2017). *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython* (2nd ed.). O'Reilly Media.